Dicionário de Dados – nycflights13

Banco de dados para práticas de SQL

O conjunto nycflights13 reúne informações sobre voos que partiram dos aeroportos JFK, LGA e EWR, em Nova York, no ano de 2013. O banco também inclui informações sobre companhias aéreas, aeroportos, aeronaves e condições meteorológicas.

1. Tabela flights

Tabela principal do banco. Cada linha representa um voo programado com origem em um dos três grandes aeroportos de Nova York.

Variável	Descrição
year	Ano da partida do voo.
month	Mês da partida.
day	Dia da partida.
dep_time	Horário real de partida, no formato HHMM ou HMM.
sched_dep_time	Horário programado de partida.
dep_delay	Atraso na partida, em minutos. Valores negativos indicam partida antecipada.
arr_time	Horário real de chegada.
sched_arr_time	Horário programado de chegada.
arr_delay	Atraso na chegada, em minutos. Valores negativos indicam chegada antecipada.
carrier	Código de duas letras da companhia aérea.
flight	Número do voo.
tailnum	Número de registro/identificação da aeronave.
origin	Código do aeroporto de origem: EWR, JFK ou LGA.
dest	Código do aeroporto de destino.
air_time	Tempo efetivamente no ar, em minutos.
distance	Distância entre origem e destino, em milhas.
hour	Hora correspondente ao horário programado de partida.
minute	Minuto correspondente ao horário programado de partida.
time_hour	Data e hora programadas da partida; útil para relacionar flights e weather.

Interpretação de atrasos:

dep_delay > 0: voo saiu atrasado; dep_delay < 0: voo saiu antes do horário. A mesma lógica vale para arr_delay em relação ao horário de chegada.

2. Tabela airlines

Tabela de referência com os códigos e nomes das companhias aéreas.

Variável	Descrição
carrier	Código de duas letras da companhia aérea.
name	Nome completo da companhia aérea.

3. Tabela airports

Contém informações geográficas e de fuso horário dos aeroportos.

Variável	Descrição
faa	Código FAA do aeroporto.
name	Nome do aeroporto.
lat	Latitude do aeroporto.
lon	Longitude do aeroporto.
alt	Altitude, em pés.
tz	Diferença de fuso horário em relação ao GMT/UTC.
dst	Indicador de uso de horário de verão.
tzone	Nome do fuso horário no padrão IANA.

4. Tabela planes

Contém características das aeronaves identificadas pelo número de registro.

Variável	Descrição
tailnum	Número de registro/identificação da aeronave.
year	Ano de fabricação da aeronave.
type	Tipo da aeronave.
manufacturer	Fabricante.
model	Modelo da aeronave.
engines	Número de motores.
seats	Número de assentos.
speed	Velocidade de cruzeiro registrada, em milhas por hora, quando disponível.
engine	Tipo de motor.

5. Tabela weather

Contém observações meteorológicas horárias nos aeroportos EWR, JFK e LGA.

Variável	Descrição
origin	Código do aeroporto/estação meteorológica.
year	Ano da observação.
month	Mês da observação.
day	Dia da observação.
hour	Hora da observação.
temp	Temperatura do ar, em graus Fahrenheit (°F).
dewp	Temperatura do ponto de orvalho, em graus Fahrenheit (°F).
humid	Umidade relativa do ar, em porcentagem.
wind_dir	Direção do vento, em graus.
wind_speed	Velocidade do vento, em milhas por hora (mph).
wind_gust	Velocidade das rajadas de vento, em milhas por hora (mph).
precip	Precipitação, em polegadas.
pressure	Pressão ao nível do mar, em milibares.
visib	Visibilidade, em milhas.
time_hour	Data e hora da observação meteorológica.

6. Principais relacionamentos entre as tabelas

Campo(s) em flights	Campo(s) relacionado(s)	Objetivo
flights.carrier	airlines.carrier	Identifica o nome da companhia aérea.
flights.tailnum	planes.tailnum	Relaciona o voo à aeronave utilizada.
flights.origin	airports.faa	Identifica o aeroporto de origem.
flights.dest	airports.faa	Identifica o aeroporto de destino.
flights.origin + flights.time_hour	weather.origin + weather.time_hour	Relaciona o voo às condições meteorológicas no horário programado.

7. Observações para uso em SQL

- Valores ausentes devem ser tratados com IS NULL ou IS NOT NULL.
- Os horários dep_time, arr_time, sched_dep_time e sched_arr_time são armazenados como números no formato aproximado HHMM.
- Para obter o nome da companhia, é necessário relacionar flights e airlines por carrier.
- A tabela airports pode ser usada duas vezes em uma mesma consulta: uma para origin e outra para dest.
- Alguns registros de flights podem não ter correspondência em planes, portanto LEFT JOIN é útil nesse relacionamento.
- O relacionamento entre flights e weather envolve mais de uma coluna, sendo um bom exemplo de chave composta.

8. Exemplos rápidos

Objetivo	Consulta SQL
Ver os primeiros voos	SELECT * FROM flights LIMIT 10;
Voos atrasados na partida	SELECT * FROM flights WHERE dep_delay > 0;
Companhias presentes na base	SELECT DISTINCT carrier FROM flights;
Média de atraso por companhia	SELECT carrier, AVG(dep_delay) AS atraso_medio FROM flights GROUP BY carrier;

Fonte: pacote R nycflights13 e documentação oficial do tidyverse.